

Instrukcja użycia skryptu do przeszukiwania plików HTML

Ten skrypt służy do przeszukiwania plików HTML i wyszukiwania fragmentów tekstu zawierających podane słowo lub frazę. Wyniki zostaną zapisane do pliku `wyniki.txt`.

1. Przygotowanie folderu z plikami

W katalogu projektu znajduje się folder:

```
input_html
```

Do tego folderu należy wrzucić swoje pliki HTML.

Można wrzucić pojedyncze pliki:

```
input_html/  
├─ strona1.html  
├─ strona2.html  
└─ strona3.html
```

Można też wrzucić cały folder z podkatalogami:

```
input_html/  
└─ moja_strona/  
    ├─ index.html  
    ├─ podstrona.html  
    └─ artykuly/  
        ├─ artykul1.html  
        └─ artykul2.html
```

Skrypt automatycznie przeszuka również podfoldery.

2. Instalacja wymaganej biblioteki

Przed pierwszym uruchomieniem trzeba zainstalować bibliotekę `beautifulsoup4`.

W terminalu wpisz:

```
pip install beautifulsoup4
```

3. Uruchomienie skryptu

Aby uruchomić skrypt z domyślnym słowem zapisanym w kodzie, wpisz:

```
python search_html.py
```

Aby wyszukać konkretne słowo, wpisz:

```
python search_html.py React
```

Aby wyszukać frazę złożoną z kilku słów, wpisz:

```
python search_html.py sztuczna inteligencja
```

4. Gdzie będą wyniki?

Po zakończeniu działania skrypt utworzy plik:

```
wyniki.txt
```

W tym pliku znajdą się wszystkie znalezione fragmenty wraz z nazwą pliku, z którego pochodzą.

Przykład wyniku:

```
=== moja_strona/artykuly/artyku11.html ===  
  
- React jest biblioteką JavaScript używaną do budowania interfejsów  
użytkownika.  
- W nauce React ważne jest zrozumienie komponentów.
```

5. Co skrypt pomija?

Skrypt analizuje głównie tekst strony. Pomija między innymi:

```
meta dane  
linki techniczne  
skrypty  
style CSS  
menu  
nagłówki  
stopki  
formularze
```

```
przyciski  
aside
```

Dzięki temu wyniki powinny zawierać przede wszystkim właściwą treść strony, a nie elementy techniczne.

6. Jak zatrzymać skrypt?

Jeżeli skrypt działa długo i chcesz go przerwać, kliknij w terminalu:

```
CTRL + C
```

To zatrzyma wykonywanie programu.

7. Najczęstsze problemy

Jeżeli pojawi się komunikat:

```
Brak katalogu: input_html
```

utwórz folder `input_html` obok pliku `search_html.py`.

Jeżeli pojawi się komunikat:

```
Nie znaleziono plików HTML
```

sprawdź, czy pliki mają rozszerzenie `.html` i czy znajdują się w folderze `input_html`.

Jeżeli polecenie `python` nie działa, spróbuj:

```
py search_html.py React
```

albo:

```
python3 search_html.py React
```